Universidad Técnica Nacional

Sede Regional de San Carlos

ISW-911 Minería de Datos

Implementación de un Data Warehouse y un Proceso ETL para Invacom Inc. S.A.

Profesor:

Freddy Gerardo Rocha Boza

Estudiantes:

Joshua Quesada Madrigal

José Fabio Oconitrillo Salazar

Maria Fernanda Sibaja Campos

Joseph Salazar Araya

17 de noviembre de 2026

Tabla de Contenido

Introducción 3

Enlace al Repositorio de Git 3

Enunciado del Problema 5

Objetivo General 5

Objetivos Específicos 6

Descripción de la Solución 7

- Requisitos del Negocio y Necesidades de los Usuarios 7
- Metodología de Trabajo 9
- Arquitectura y Herramientas 10
- Fuentes de Datos 11
- Evaluación de la Calidad de los Datos 13
- Modelo Dimensional 14
- Infraestructura del Data Warehouse 17
- Proceso ETL 17
- Validación y Pruebas 20
- Informes y Consultas en Excel 24

Diagrama del Modelo Dimensional 28

Conclusión 29

Referencias 30

Anexo A: Porcentaje de Participación 31

Introducción

Las empresas que venden en línea generan a diario miles de registros de órdenes, pagos, entregas y reseñas. Esos datos se guardan en bases transaccionales diseñadas para operar el negocio, no para analizarlo: responder una pregunta tan simple como cuánto se vendió por región obliga a unir varias tablas y a conocer reglas que no están escritas en ningún lugar. Un Data Warehouse (DW) resuelve ese problema al reorganizar la información en un modelo orientado al análisis, integrado, histórico y no volátil (Inmon, 2005).

Este documento presenta la solución desarrollada para Invacom Inc. S.A. en el Proyecto #1 del curso Minería de Datos. A partir de la base operativa entregada por el profesor, que corresponde al conjunto público de comercio electrónico de Olist (Brasil, 2016-2018), el equipo diseñó un modelo dimensional, construyó un proceso de Extracción, Transformación y Carga (ETL) en Python con Pandas y SQLAlchemy sobre Oracle, y conectó Excel al DW para responder siete preguntas de negocio mediante tablas dinámicas.

El trabajo se organizó con el marco ágil Scrum en tres sprints semanales, con un tablero Kanban en GitHub Projects y el control de versiones en un repositorio de Git compartido. Las secciones siguientes describen el problema, los objetivos, la fuente de datos y su calidad, el modelo dimensional, el proceso ETL, las pruebas de validación y los resultados de los informes, y cierran con las conclusiones del equipo.

Enlace al Repositorio de Git

El código, los scripts SQL, la documentación técnica y las evidencias de avance se encuentran en el repositorio público https://github.com/joshuaqm11/DataWarehouse_Invacom. El tablero Kanban del proyecto está en GitHub Projects con el nombre *Proyecto Data Warehouse + ETL - Invacom*, donde cada tarjeta indica el sprint y el responsable.

El repositorio sigue la estructura sugerida en la guía del proyecto: la carpeta *sql/exploracion* contiene las consultas de inventario y perfilado de la fuente; *sql/dw* los scripts de creación del DW (usuario, dimensiones, hechos, bitácora, database links y vistas para Excel); *sql/validacion* las consultas de control; *etl* el código Python; *informes* el libro de Excel, y *docs* el modelo, las reglas de calidad, las actas de cada sprint y las capturas de evidencia. Las credenciales nunca se suben al repositorio: cada integrante usa un archivo *.env* local excluido por *.gitignore*.

Tabla 1

Avance Semanal Registrado en el Repositorio

Sprint	Fechas	Incremento entregado (evidencia en Git)
Sprint 1	17 al 23 de octubre	Estructura del repositorio, DDL del DW, ETL completo con validación y reejecución sin duplicados, database links, vistas para Excel, siete informes y Tablero
Sprint 2	24 al 30 de octubre	Diagramas del modelo y de la fuente, conclusiones de los informes, consulta de cuadre por año, actas, README y tablero Kanban
Sprint 3	31 de octubre al 6 de noviembre	Perfilado de calidad, inventario de la fuente, requisitos, evidencias de informes, hoja de KPI, prueba de recuperación ante fallo, guía de Excel, guía de la demostración y tabla de participación

Enunciado del Problema

Invacom Inc. S.A. registra su operación de comercio electrónico en nueve tablas operativas separadas: órdenes, ítems, pagos, reseñas, clientes, vendedores, productos, traducción de categorías y geolocalización, con cerca de 1.55 millones de filas en total. Esa estructura sirve para operar, pero no para analizar.

En primer lugar, para responder cualquier pregunta de negocio hay que unir varias tablas y conocer reglas no documentadas; por ejemplo, la fuente crea un identificador de cliente nuevo en cada orden, de modo que contar clientes con ese campo da un resultado inflado. En segundo lugar, las tablas no tienen llaves primarias ni foráneas declaradas y presentan problemas de calidad: códigos postales repetidos más de un millón de veces, ciudades escritas de distintas formas, productos sin categoría y fechas almacenadas como texto. Por último, no existe un calendario ni indicadores calculados como los días de entrega, el cumplimiento del plazo o la región del cliente.

En consecuencia, la gerencia y las áreas del negocio no cuentan con una forma confiable y rápida de conocer cómo evolucionan las ventas, dónde se concentran, cómo pagan los clientes ni qué afecta su satisfacción.

Objetivo General

Implementar un Data Warehouse con modelo dimensional, alimentado mediante un proceso ETL en Python (SQLAlchemy y Pandas) desde la base operativa de Invacom Inc. S.A., que integre y limpie los datos de ventas, pagos, entregas y reseñas para responder las preguntas de negocio de la empresa desde tablas dinámicas en Excel.

Objetivos Específicos

Los objetivos específicos se definieron con metas medibles, de modo que su cumplimiento se pudiera comprobar con evidencia concreta (ver Tabla 2).

Tabla 2

Objetivos Específicos, Metas y Evidencia de Cumplimiento

#	Objetivo	Meta	Evidencia
OE1	Cargar completamente los hechos de la fuente	100 % de las filas: 112,650 ítems y 103,886 pagos, con 0 filas rechazadas	Bitácora del ETL y validación automática
OE2	Garantizar la exactitud de los montos	Cuadre al centavo con la fuente: 15,843,553.24 BRL en ventas y 16,008,872.12 BRL en pagos	Validación fuente contra DW
OE3	Asegurar una carga reproducible	Reejecutar el ETL sin duplicar filas y completar la carga en menos de un minuto	Evidencias de ejecución y reejecución
OE4	Tratar los problemas de calidad con reglas documentadas	Cada problema del perfilado se asocia con una regla de transformación (R01 a R18)	Registro de calidad y reglas del ETL
OE5	Responder las preguntas de negocio desde Excel	Siete preguntas respondidas con tablas dinámicas conectadas al DW	Libro Informes_DW_Invacom.xlsx

Descripción de la Solución

La solución sigue el orden de tareas del enunciado: primero se entendieron el negocio y la fuente, después se diseñó el modelo dimensional y, solo entonces, se programó el ETL que lo alimenta. Esta sección resume cada etapa y las decisiones técnicas que la sustentan.

Requisitos del Negocio y Necesidades de los Usuarios

El propósito del proyecto es dar a Invacom una fuente única y confiable para analizar sus ventas en línea. Para concretarlo, el equipo identificó a los usuarios finales del DW, la información que cada uno necesita y el informe que la atiende (ver Tabla 3). De esas necesidades surgieron siete preguntas de negocio que guiaron el diseño, y cada una se validó contra las tablas reales para no prometer métricas que la fuente no permite calcular.

Tabla 3

Usuarios del Data Warehouse y sus Necesidades de Información

Usuario	Necesidad	Informe que la atiende
Gerencia	Visión general del negocio y su evolución	Tablero e Informe 1
Área comercial	Saber qué se vende, dónde y quién vende más	Informes 2, 3 y 4
Logística	Medir tiempos de entrega y cumplimiento por región	Informe 5
Servicio al cliente	Entender qué afecta la satisfacción	Informe 6
Finanzas	Conocer los medios de pago y el uso de cuotas	Informe 7

Tabla 4

Preguntas de Negocio que Responde el Data Warehouse

#	Pregunta	Dimensiones	Medidas
1	¿Cómo evolucionan las ventas en el tiempo?	Tiempo (año, mes)	Ventas
2	¿Qué categorías generan más ingreso y cuánto pesa el flete?	Producto (categoría)	Ventas, flete, flete ÷ precio
3	¿Dónde se concentran las compras?	Cliente (región, estado)	Ventas, % del total
4	¿Qué vendedores facturan más?	Vendedor (código, estado)	Ventas
5	¿Cuánto tarda la entrega y qué porcentaje llega a tiempo por región?	Cliente (región), tiempo	Días de entrega, % a tiempo
6	¿El atraso en la entrega baja la satisfacción?	Rango de atraso	Puntuación promedio, % de reseñas de 1 estrella
7	¿Cómo pagan los clientes y en cuántas cuotas?	Tipo de pago, rango de cuotas	Monto pagado, cantidad y promedio de pagos

El alcance incluye ventas, pagos, entregas y puntuación de reseñas de 2016 a 2018. Quedan fuera el texto libre de las reseñas, los nombres de clientes y vendedores (la fuente está anonimizada) y los costos o márgenes, que la fuente no contiene.

Metodología de Trabajo

El proyecto se gestionó con Scrum adaptado al entorno académico (Schwaber & Sutherland, 2020). Joshua asumió el rol de Scrum Master y coordinador, y el profesor actuó como Product Owner. El trabajo se dividió en tres sprints de una semana; al inicio de cada uno el equipo eligió las tarjetas del Product Backlog en el tablero Kanban, las actualizaciones diarias se hicieron de forma asíncrona por WhatsApp (qué hice, qué haré, bloqueos) y cada cierre quedó registrado en un acta con lo completado, lo pendiente y las decisiones tomadas. Las tareas se trabajaron en ramas por tarjeta con revisión de otro integrante antes de integrarse a la rama principal.

Tabla 5

Responsabilidades Principales del Equipo

Integrante	Responsabilidades
Joshua	Scrum Master y coordinador; DDL del DW; ETL completo (extracción, transformación, carga, validación y bitácora); actas; máquina y guía de la demostración
Fernanda	Inventario y perfilado de calidad de la fuente; requisitos y objetivos; database links y cuadre staging-producción; documento APA 7
Fabio	Vistas para Excel; conexión Excel-Oracle; informes 1 a 4; prueba de recuperación ante fallo; guía de Excel
Joseph	Informes 5 a 7; Tablero y hoja de KPI; diagramas del modelo y de la fuente; conclusiones de los informes

Arquitectura y Herramientas

La arquitectura tiene tres capas. La **fuente** son las nueve tablas STG_* cargadas en Oracle, que el ETL solo lee y nunca modifica. El **proceso ETL**, escrito en Python, extrae esas tablas con consultas SQL explícitas mediante SQLAlchemy y el controlador python-oracledb, las transforma en memoria con Pandas y carga el resultado en el **destino**, un esquema separado llamado DW_INVACOM. Finalmente, Excel se conecta a tres vistas del DW con Power Query para las tablas dinámicas.

De las opciones del enunciado, el equipo eligió Python (Pandas + SQLAlchemy) porque permite documentar cada regla de limpieza en el código, versionarlo en Git como cualquier otro programa, controlar la transacción completa de la carga y ejecutar el proceso de punta a punta con un solo comando. El código está separado en módulos con una responsabilidad cada uno (ver Tabla 6).

Tabla 6

Módulos del Proceso ETL

Módulo	Responsabilidad
extract.py	Consultas explícitas a las tablas STG_*, sin SELECT *
transform.py	Limpieza, enriquecimiento y construcción de dimensiones y hechos (reglas R01 a R18)
load.py	MERGE de dimensiones, carga de hechos en una sola transacción y registro en la bitácora
validar.py	Cuadre de conteos y montos entre la fuente y el DW, y controles de integridad
main.py	Orquestación de las cuatro fases y resumen de la ejecución
config.py / .env	Parámetros de conexión locales; las credenciales no se versionan

Fuentes de Datos

La fuente es la base pública Olist E-commerce (Olist, 2018), cargada en el esquema de staging de cada integrante. La Tabla 7 resume su inventario y la Figura 1 muestra las relaciones entre tablas. Como ninguna tabla trae claves primarias ni foráneas declaradas, las relaciones se identificaron por el significado de los campos y se comprobaron con consultas, sin asumirlas solo por el parecido de los nombres.

Tabla 7

Inventario de las Tablas Fuente

Tabla	Filas	Una fila representa…
STG_ORDERS	99,441	Una orden de compra
STG_ORDER_ITEMS	112,650	Un producto (ítem) dentro de una orden
STG_ORDER_PAYMENTS	103,886	Un pago de una orden (puede haber varios)
STG_ORDER_REVIEWS	99,224	Una reseña de una orden
STG_CUSTOMERS	99,441	Un cliente por orden
STG_SELLERS	3,095	Un vendedor
STG_PRODUCTS	32,951	Un producto
STG_PRODUCT_CATEGORY_TRANSLATION	71	Una categoría con su nombre en inglés
STG_GEOLOCATION	1,000,163	Una coordenada de un código postal
Total	1,550,922	

Nota. Todas las columnas aceptan nulos; las fechas están almacenadas como texto (VARCHAR2) en unas máquinas del equipo y como DATE en otras, y el ETL convierte ambos formatos.

Figura 1

Relaciones entre las Tablas de la Fuente Olist



Del análisis de relaciones se derivaron tres hallazgos que condicionaron el diseño: el identificador *customer_id* cambia en cada orden y la persona real es *customer_unique_id* (99,441 identificadores corresponden a 96,096 clientes reales); el vendedor está en el ítem y no en la orden, por lo que una orden puede tener varios vendedores; y la tabla de geolocalización tiene

muchas coordenadas por código postal, lo que exige reducirla antes de unirla con clientes y vendedores.

Evaluación de la Calidad de los Datos

La calidad se evaluó con consultas de perfilado sobre las tablas fuente (script *02_perfilado_calidad.sql*) que revisaron claves duplicadas, nulos, integridad referencial, consistencia de formatos, valores atípicos y secuencias de fechas imposibles. La Tabla 8 resume los hallazgos más relevantes y el tratamiento acordado; cada tratamiento corresponde a una regla del ETL. La consigna del equipo fue no limpiar valores de forma arbitraria: lo que no se puede corregir con certeza se conserva como nulo o desconocido, y nada se descarta en silencio.

Tabla 8

Hallazgos del Perfilado de Calidad y Tratamiento Aplicado

Problema	Resultado del perfilado	Tratamiento (regla)
Claves duplicadas	0 duplicados en órdenes, clientes, productos, vendedores e ítems	Si aparecieran, se rechazan y se registran (R18)
Cliente repetido	99,441 customer_id corresponden a 96,096 clientes reales	Dimensión por customer_unique_id con la dirección de la orden más reciente (R06)
Reseñas múltiples	547 órdenes con más de una reseña	Se toma la reseña respondida más recientemente (R13)
Geolocalización repetida	1,000,163 filas para 19,015 códigos postales; 42 coordenadas fuera de Brasil	Se descartan las externas y se promedia: 19,010 códigos únicos (R04)
Productos incompletos	610 sin categoría; 2 sin peso; 2 sin medidas	Categoría sin_categoria; medidas nulas se conservan (R07, R09)

Problema	Resultado del perfilado	Tratamiento (regla)
Categorías sin traducción	pc_gamer y portateis_cozinha_e_preparadores_de_alimentos	Traducción manual documentada (R08)
Ciudades inconsistentes	"sao paulo" 135,800; "são paulo" 24,918; "sãopaulo" 2	Minúsculas, sin tildes y espacios simples (R03)
Fechas faltantes o imposibles	Órdenes sin entrega por su estado; 166 enviadas antes de la compra; 23 entregadas antes del envío	Se conservan; medidas de días en nulo y fecha -1 "Sin fecha" (R15)
Pagos con 0 cuotas	2 pagos	Se interpretan como pago de contado: 1 cuota (R16)
Huérfanos	775 órdenes sin ítems; 1 orden sin pago; 157 códigos postales de clientes sin geolocalización	Los hechos apuntan al miembro -1 "Desconocido" (R17)
Pago ≠ precio + flete	249 órdenes con diferencia mayor a 1 BRL	Ventas y pagos se modelan en hechos separados

Modelo Dimensional

El modelo se diseñó con el procedimiento de cuatro pasos de Kimball y Ross (2013): elegir el proceso de negocio, declarar la granularidad, identificar las dimensiones e identificar los hechos. Se reconocieron dos procesos distintos, la **venta de productos** y el **cobro de las órdenes**, que se modelaron en dos tablas de hechos: FACT_VENTAS y FACT_PAGOS.

La separación responde a una razón concreta. El precio y el flete existen por ítem, mientras que los pagos existen por orden y una orden puede tener varios. Si se unieran en una sola tabla, el monto pagado se repetiría en cada ítem y quedaría duplicado al sumar; además, el perfilado mostró 249 órdenes donde el pago no coincide con precio más flete. Ambas tablas comparten las dimensiones de tiempo, cliente y estado de la orden, por lo que el resultado es una constelación de dos esquemas estrella. No se usó copo de nieve: las jerarquías (ciudad, estado y

región; día, mes, trimestre y año) se guardan desnormalizadas dentro de cada dimensión, porque su volumen es pequeño (menos de 100 mil filas) y así Excel las usa directamente con menos uniones. El diagrama completo se presenta en la sección siguiente.

Granularidad

- **FACT_VENTAS:** una fila equivale a un ítem dentro de una orden (*order_id* + *order_item_id*). Si una orden compra tres unidades del mismo producto, hay tres filas. Volumen: 112,650 filas.
- **FACT_PAGOS:** una fila equivale a un pago registrado de una orden (*order_id* + *payment_sequential*). Volumen: 103,886 filas.

Dimensiones

Todas las dimensiones tienen una clave sustituta (*sk_*) y un registro -1 "Desconocido" al que apuntan los hechos cuya referencia no se puede resolver; así ningún hecho se pierde y la integridad referencial se mantiene. La dimensión de tiempo cumple dos roles en FACT_VENTAS: fecha de compra y fecha de entrega.

Tabla 9

Dimensiones del Data Warehouse

Dimensión	Clave natural	Atributos principales	Fuente
DIM_TIEMPO	Fecha (clave AAAAMMDD)	Año, trimestre, mes, nombre de mes, día, día de la semana, fin de semana	Calendario generado por el ETL (800 días)
DIM_CLIENTE	customer_unique_id	Código postal, ciudad, estado, región*, latitud, longitud	STG_CUSTOMERS + STG_GEOLOCATION

Dimensión	Clave natural	Atributos principales	Fuente
DIM_VENDEDOR	seller_id	Código postal, ciudad, estado, región*, latitud, longitud	STG_SELLERS + STG_GEOLOCATION
DIM_PRODUCTO	product_id	Categoría en portugués e inglés, peso, medidas, volumen*, rango de peso*, fotos	STG_PRODUCTS + traducción
DIM_ESTADO_ORDEN	order_status	Estado en español, indicador de completada	STG_ORDERS
DIM_TIPO_PAGO	payment_type	Tipo de pago en español	STG_ORDER_PAYMENTS

Medidas

Tabla 10

Medidas de las Tablas de Hechos

Medida	Fórmula	Unidad	Tipo
FACT_VENTAS			
Cantidad	1 por fila	unidades	Aditiva
Precio	price	BRL	Aditiva
Flete	freight_value	BRL	Aditiva
monto_total	precio + flete	BRL	Aditiva
dias_entrega	Fecha de entrega − fecha de compra	días	No aditiva (promedio)
dias_atraso	Fecha de entrega − fecha estimada	días	No aditiva (promedio)
entregado_a_tiempo	1 si entrega ≤ estimada; 0 si no; nulo si no se entregó	indicador	Semiaditiva

Medida	Fórmula	Unidad	Tipo
review_score	Puntuación 1 a 5 de la orden	puntos	No aditiva (promedio)
FACT_PAGOS			
monto_pago	payment_value	BRL	Aditiva
Cuotas	payment_installments	cuotas	No aditiva (promedio)

El *order_id* se conserva en ambos hechos como dimensión degenerada, lo que permite contar órdenes distintas sin crear una dimensión sin atributos propios.

Infraestructura del Data Warehouse

El DW reside en un usuario y esquema propio de Oracle, DW_INVACOM, separado de las tablas fuente para no mezclar ni modificar los datos originales. Los scripts de *sql/dw* se ejecutan en orden: creación del usuario (00), dimensiones (01), hechos con sus claves primarias y foráneas (02), bitácora de cargas ETL_LOG_CARGA (03), database links entre staging y producción (04) y vistas para Excel (05). Existe además un script (99) que elimina todo el DW para reconstruirlo desde cero. Gracias a esto, cada integrante pudo levantar el mismo DW en su base local a partir del repositorio.

Proceso ETL

Extracción

El módulo de extracción lee las nueve tablas STG_* con consultas SQL explícitas que piden solo las columnas necesarias. La conexión se crea con SQLAlchemy y el controlador python-oracledb a partir de parámetros locales, y cada lectura informa la cantidad de filas extraídas en la bitácora.

Transformación

La transformación se hace en memoria con Pandas y aplica 18 reglas codificadas (R01 a R18), cada una comentada en el código y descrita en la Tabla 11. Las reglas se agrupan en cuatro tipos: limpieza (espacios, códigos postales a cinco dígitos, normalización de ciudades), integración (cliente real, una reseña por orden, geolocalización promedio por código postal), enriquecimiento (región, volumen, rango de peso, calendario, traducciones al español) y control (rechazo de duplicados y montos inválidos, miembro desconocido para referencias no resueltas). Las filas que no pueden cargarse se guardan con su motivo en un archivo de rechazados.

Tabla 11

Reglas de Transformación del ETL

Regla	Problema	Transformación aplicada
R01	Claves con espacios o vacías	strip(); cadena vacía → nulo
R02	Códigos postales sin ceros a la izquierda	Relleno a cinco dígitos
R03	Ciudades con tildes, mayúsculas y espacios distintos	Minúsculas, sin tildes, espacios simples
R04	Geolocalización repetida y coordenadas fuera de Brasil	Filtro geográfico y una fila por código postal con coordenadas promedio
R05	El estado no indica la región	Estado → región oficial del IBGE
R06	customer_id distinto en cada orden	Una fila por customer_unique_id (SCD tipo 1)
R07	Productos sin categoría	Categoría sin_categoria
R08	Categorías sin traducción	Catálogo de traducción manual
R09	Peso o medidas nulas o negativas	Se dejan en nulo; no se inventan valores
R10	Peso sin agrupar	Rango de peso y volumen calculado

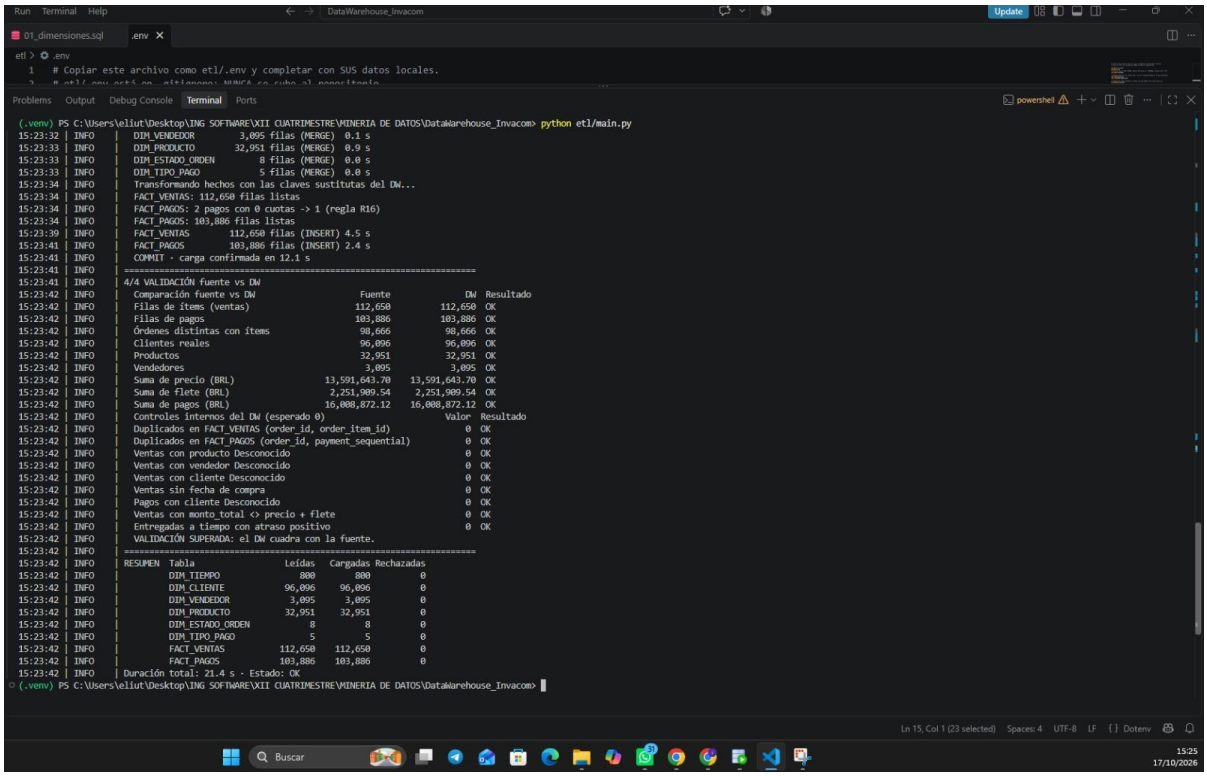
Regla	Problema	Transformación aplicada
R11	Estados y tipos de pago en inglés	Traducción al español
R12	No existe calendario	Calendario continuo del rango de fechas de las órdenes
R13	Varias reseñas por orden	Reseña más reciente; puntuación fuera de 1 a 5 se rechaza
R14	Precios o fletes nulos o negativos	Se rechaza el ítem
R15	Órdenes sin entrega o con fechas imposibles	Medidas de días en nulo; fecha -1 "Sin fecha"
R16	Pagos con 0 cuotas	Pago de contado: 1 cuota
R17	Hechos sin dimensión válida	Se cargan apuntando al miembro -1 "Desconocido"
R18	Ítems o pagos duplicados o sin orden	Se rechazan y se registran con su motivo

Carga

La carga respeta el orden de las dependencias: primero las dimensiones, luego se recuperan sus claves sustitutas y después se insertan los hechos. Las dimensiones se cargan con MERGE por clave natural, de modo que sus claves se mantienen estables entre ejecuciones, y los hechos se recargan por completo (DELETE + INSERT) dentro de la misma transacción. Si cualquier paso falla, se ejecuta ROLLBACK y el DW queda exactamente como estaba antes; si todo termina bien, se confirma con COMMIT. Con esta estrategia el ETL se puede ejecutar las veces que se quiera sin duplicar datos. Cada ejecución registra en la tabla ETL_LOG_CARGA y en un archivo de log las filas leídas, cargadas y rechazadas, el estado y la duración (Kimball & Caserta, 2004).

Figura 2

Ejecución Completa del ETL con Validación y Resumen de Carga



Captura de la ejecución del 17 de octubre de 2026: 112,650 ventas y 103,886 pagos cargados, 0 rechazados, validación superada en 21.4 segundos.

Validación y Pruebas

Que el script termine sin error no garantiza que los datos estén bien, por lo que el ETL incluye una fase automática de validación que compara la fuente con el DW y ejecuta controles de integridad. Además, el equipo realizó pruebas adicionales de reejecución, recuperación ante fallo y cuadre con database links (ver Tabla 12).

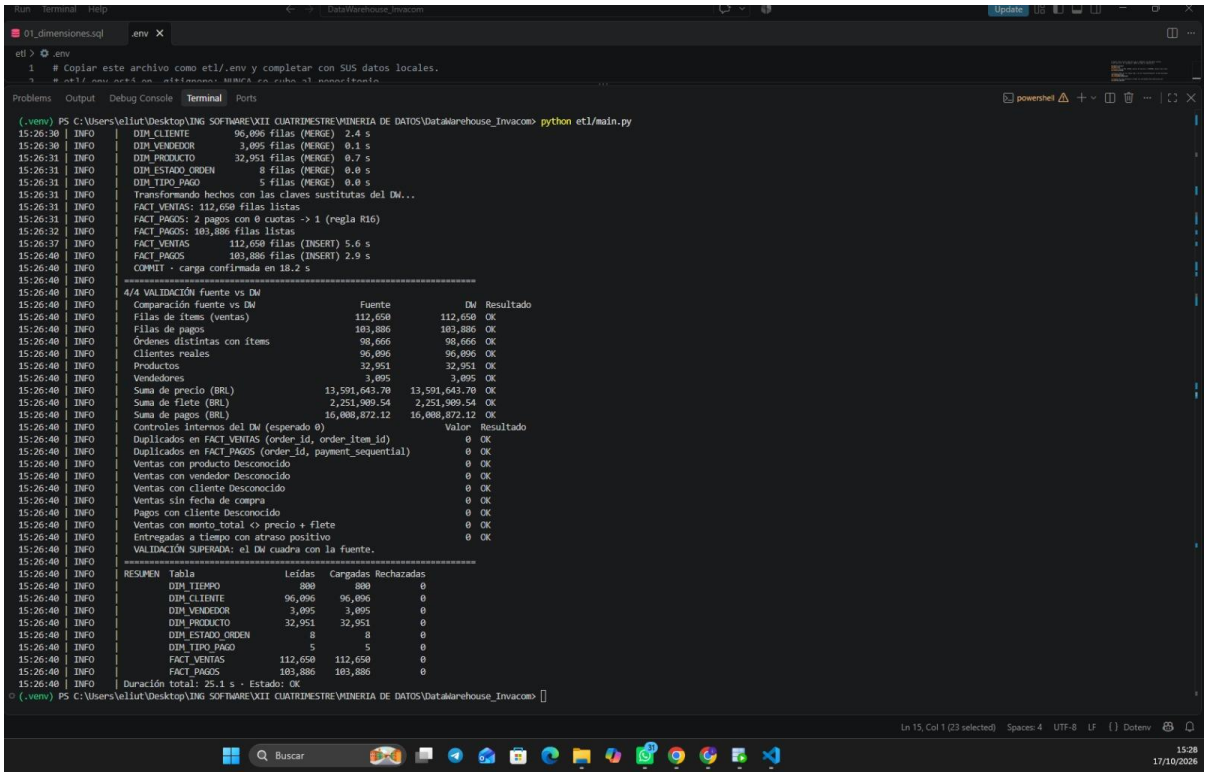
Tabla 12

Pruebas Realizadas y Resultados

Prueba	Qué se comprobó	Resultado
Conteos	Ítems, pagos, órdenes, clientes reales, productos y vendedores en la fuente contra el DW	Coinciden en todos los casos
Montos	Suma de precio, flete y pagos con tolerancia de 0.01 BRL	13,591,643.70 + 2,251,909.54 = 15,843,553.24 BRL en ventas; 16,008,872.12 BRL en pagos
Duplicados	Claves de FACT_VENTAS y FACT_PAGOS	0 duplicados
Claves	Hechos que apuntan al miembro desconocido	0 en producto, vendedor, cliente y fecha de compra
Coherencia	monto_total = precio + flete; entregas a tiempo sin atraso positivo	0 inconsistencias
Reejecución	Correr el ETL dos veces seguidas	Se mantienen 112,650 y 103,886 filas (no se duplican)
Recuperación	Provocar un error a mitad de la carga	ROLLBACK; el DW queda igual que antes de la ejecución
Cuadre con dblinks	Comparar fila por fila staging contra producción con MINUS	Diferencia 0; un cambio simulado se detecta y se revierte

Figura 3

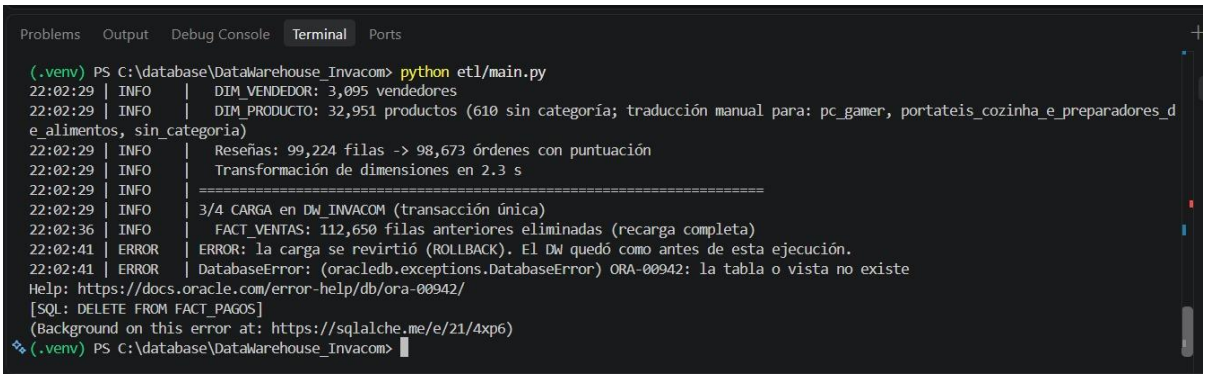
Reejecución del ETL sin Duplicar Registros



Nota. Segunda ejecución consecutiva: los conteos del DW siguen siendo 112,650 y 103,886, y la validación vuelve a ser satisfactoria.

Figura 4

Prueba de Recuperación ante Fallo

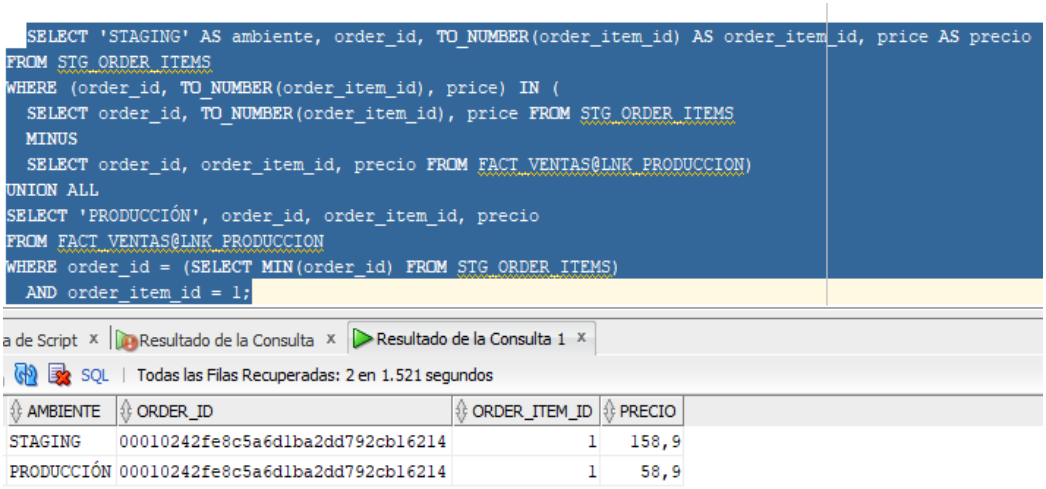


Al forzar un error durante la carga, el ETL revierte la transacción (ROLLBACK) y el DW conserva su estado anterior.

La prueba de cuadre usa database links entre el esquema de staging y el DW para comparar los datos fila por fila. Para demostrar que el control funciona, se modificó temporalmente el precio de un ítem en staging; el cuadre detectó la diferencia de inmediato (ver Figura 5) y, después de un ROLLBACK, volvió a reportar cero diferencias.

Figura 5

Diferencia Detectada por el Cuadre entre Staging y Producción



```
SELECT 'STAGING' AS ambiente, order_id, TO_NUMBER(order_item_id) AS order_item_id, price AS precio
FROM STG_ORDER_ITEMS
WHERE (order_id, TO_NUMBER(order_item_id), price) IN (
  SELECT order_id, TO_NUMBER(order_item_id), price FROM STG_ORDER_ITEMS
  MINUS
  SELECT order_id, order_item_id, precio FROM FACT_VENTAS@LNK_PRODUCCION)
UNION ALL
SELECT 'PRODUCCIÓN', order_id, order_item_id, precio
FROM FACT_VENTAS@LNK_PRODUCCION
WHERE order_id = (SELECT MIN(order_id) FROM STG_ORDER_ITEMS)
  AND order_item_id = 1;
```

a de Script | Resultado de la Consulta | Resultado de la Consulta 1

SQL | Todas las Filas Recuperadas: 2 en 1.521 segundos

AMBIENTE	ORDER_ID	ORDER_ITEM_ID	PRECIO
STAGING	00010242fe8c5a6d1ba2dd792cb16214	1	158,9
PRODUCCIÓN	00010242fe8c5a6d1ba2dd792cb16214	1	58,9

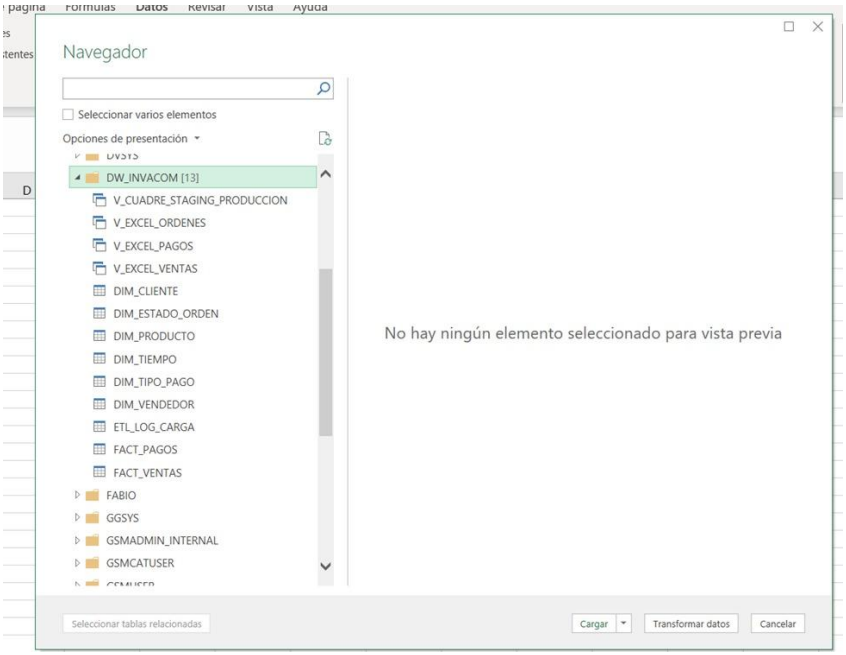
El precio modificado en staging (158.9) no coincide con el del DW (58.9); el cambio se revirtió con ROLLBACK.

Informes y Consultas en Excel

Excel se conecta directamente a Oracle mediante Power Query (Microsoft, s.f.) con el cliente Oracle Client for Microsoft Tools. Para que ninguna medida se sume dos veces, el DW expone tres vistas, cada una con una sola granularidad: V_EXCEL_VENTAS (una fila por ítem, 112,650 filas), V_EXCEL_ORDENES (una fila por orden, 98,666 filas) y V_EXCEL_PAGOS (una fila por pago, 103,886 filas). Las vistas ya traen los nombres en español y unen hechos con dimensiones, de modo que las tablas dinámicas no requieren uniones. Cuando el ETL carga datos nuevos, basta con usar *Datos* → *Actualizar todo*.

Figura 6

Conexión de Excel al Esquema DW_INVACOM



Navegador de Power Query con las tablas y vistas del DW disponibles para las tablas dinámicas.

El libro *Informes_DW_Invacom.xlsx* contiene siete informes, uno por pregunta de negocio, y un Tablero con los indicadores principales y filtros por año y región (ver Figura 7). La Tabla 13 resume la respuesta de cada informe. En los informes de ventas se excluyen las órdenes canceladas o no disponibles para medir solo ventas efectivas (15,735,527.03 BRL); el total sin filtro es 15,843,553.24 BRL.

Tabla 13

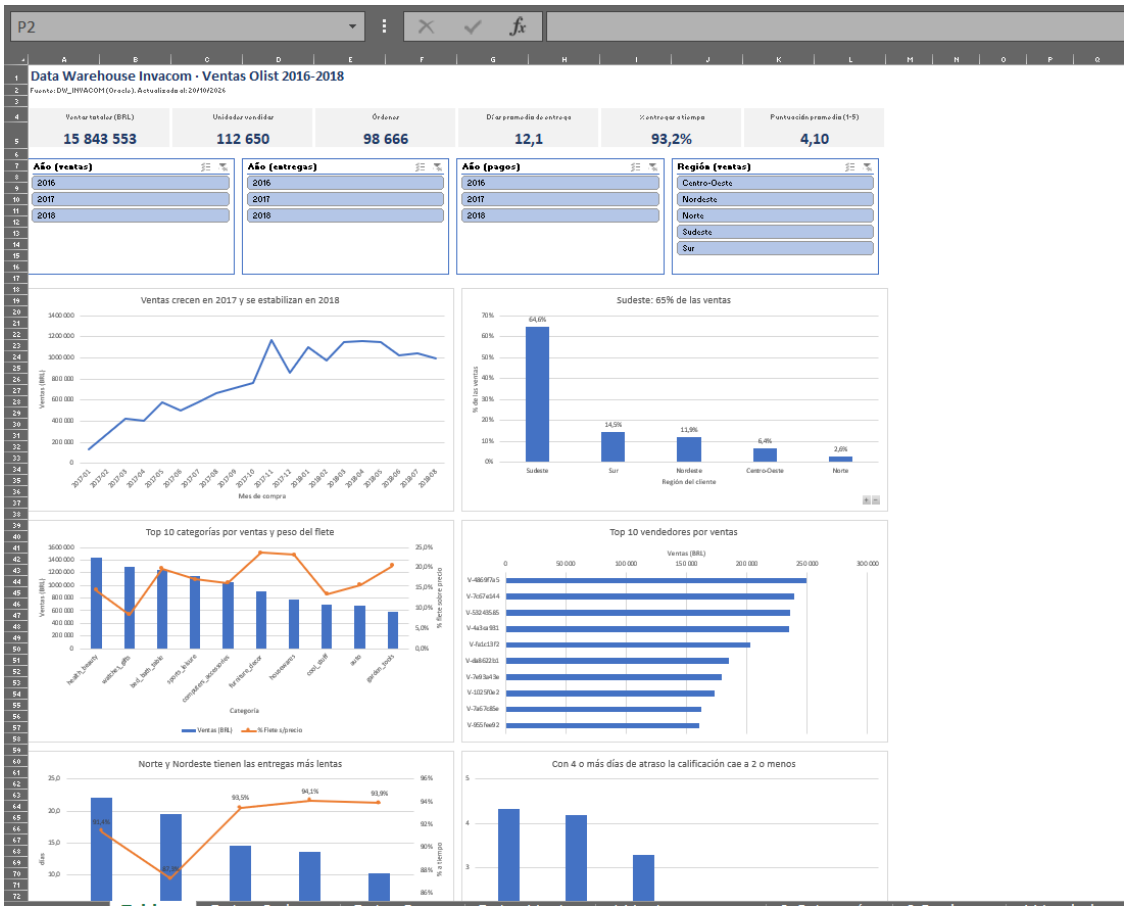
Resultados Principales de los Informes

Informe	Hallazgo
1. Ventas por mes	Crecimiento sostenido en 2017 (de 136,943 BRL en enero a 764,756 BRL en octubre); noviembre de 2017 es el mes más alto (1,172,192 BRL, Black Friday); en 2018 se estabilizan entre 0.98 y 1.16 millones BRL mensuales
2. Categorías y flete	Salud y belleza (9.1 %), relojes y regalos (8.3 %) y cama, mesa y baño (7.9 %) lideran; en muebles y hogar el flete supera el 23 % del precio
3. Regiones	El Sudeste concentra el 64.6 % de las ventas; Norte y Nordeste suman 14.5 %
4. Vendedores	Los 10 principales suman 12.9 % de las ventas entre 3,053 vendedores; 9 de ellos están en São Paulo
5. Entregas	Promedio de 12.1 días y 93.2 % a tiempo; Norte (22.1 días) y Nordeste (19.5 días) tardan casi el doble que el Sudeste (10.3 días)
6. Atraso y satisfacción	Con 4 o más días de atraso la puntuación cae a 2.1 o menos y más del 58 % de las reseñas son de 1 estrella
7. Pagos	La tarjeta de crédito concentra el 78.3 % del monto pagado; los pagos en 7 o más cuotas triplican el monto promedio del pago de contado

Cifras tomadas de las tablas dinámicas conectadas a las vistas V_EXCEL_*. Montos en reales brasileños (BRL).

Figura 7

Tablero de Indicadores en Excel Conectado al DW



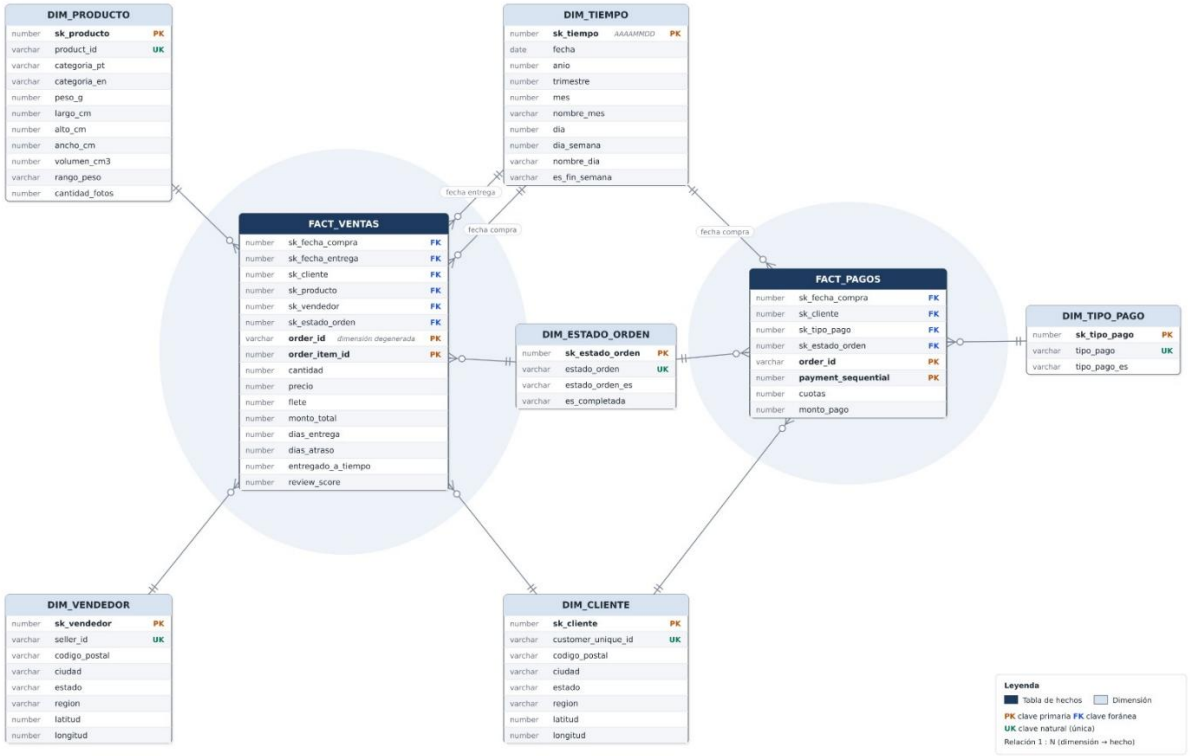
- Ventas totales 15,843,553 BRL
- 112,650 unidades
- 98,666 órdenes
- 12.1 días promedio de entrega
- 93.2 % a tiempo
- Puntuación promedio 4.10.

Diagrama del Modelo Dimensional

La Figura 8 presenta el modelo dimensional implementado: una constelación formada por dos esquemas estrella, FACT_VENTAS y FACT_PAGOS, que comparten las dimensiones de tiempo, cliente y estado de la orden. Se indican las claves primarias (PK), foráneas (FK) y únicas (UK) de cada tabla.

Figura 8

Modelo Dimensional del Data Warehouse Invacom (Constelación de Dos Estrellas)



Conclusión

El proyecto cumplió su objetivo general: Invacom cuenta con un Data Warehouse operativo en Oracle, alimentado por un ETL en Python que carga el 100 % de las ventas y los pagos de la fuente, cuadra al centavo con ella, se ejecuta en unos 25 segundos y puede repetirse sin duplicar información. Las siete preguntas de negocio quedaron respondidas desde Excel con datos que se actualizan directamente del DW.

Las decisiones de diseño fueron determinantes para la exactitud de los resultados. Separar ventas y pagos en dos tablas de hechos evitó duplicar montos; construir la dimensión cliente por el identificador real evitó inflar el número de clientes; y publicar una vista por granularidad impidió que Excel sumara o promediara medidas de forma incorrecta. Del mismo modo, documentar cada problema de calidad con una regla explícita permitió explicar cada cifra del DW en lugar de limpiar datos de forma arbitraria.

Desde el punto de vista del negocio, los informes muestran que Invacom vende principalmente en el Sudeste, mediante tarjeta de crédito en cuotas, con un crecimiento fuerte en 2017 y estable en 2018. El principal riesgo para la satisfacción del cliente es la logística en las regiones Norte y Nordeste, donde las entregas son más lentas y el atraso es el factor que más reduce las calificaciones; mejorar esos tiempos protegería la reputación de la empresa y abriría crecimiento en las regiones con menor participación.

En cuanto al proceso, trabajar con Scrum, Git y un tablero Kanban permitió tener el DW funcional desde el primer sprint y dedicar el tiempo restante a validar, documentar y analizar. Como aprendizaje, el equipo identificó la necesidad de repartir los commits de forma más pareja cada semana. El DW construido queda como base para el Proyecto #2, en el que se desarrollará un tablero de indicadores clave sobre el mismo modelo.

Referencias

Bayer, M. (2024). *SQLAlchemy 2.0 documentation*. SQLAlchemy. https://docs.sqlalchemy.org/en/20/

Inmon, W. H. (2005). *Building the data warehouse* (4.ª ed.). Wiley.

joshuaqm11. (2026). *DataWarehouse_Invacom* [Repositorio de código fuente]. GitHub. https://github.com/joshuaqm11/DataWarehouse_Invacom

Kimball, R., & Caserta, J. (2004). *The data warehouse ETL toolkit: Practical techniques for extracting, cleaning, conforming, and delivering data*. Wiley.

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3.ª ed.). Wiley.

Microsoft. (s.f.). *Documentación de Power Query*. Microsoft Learn. https://learn.microsoft.com/es-es/power-query/

Olist. (2018). *Brazilian e-commerce public dataset by Olist* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

Oracle. (s.f.). *python-oracledb documentation*. https://python-oracledb.readthedocs.io/

Schwaber, K., & Sutherland, J. (2020). *La guía de Scrum: La guía definitiva de Scrum: Las reglas del juego*. https://scrumguides.org/

The pandas development team. (2024). *pandas documentation* (Versión 2.2). https://pandas.pydata.org/docs/

Universidad Técnica Nacional. (2026). *Proyecto #1 Minería de datos 3C2026* [Enunciado del proyecto]. Curso ISW-911 Minería de Datos.

Anexo A: Porcentaje de Participación

De acuerdo con el enunciado, el coordinador del grupo evaluó el aporte individual de cada integrante con la escala de participación definida por el profesor. El criterio fue la participación en todos los sprints según las actas y el tablero Kanban, y los aportes registrados en el historial de Git.

Tabla 14

Porcentaje de Participación por Integrante

Integrante	Aporte principal	Commits	Participación
Joshua	Estructura del repositorio, DDL, ETL completo, README, actas, Kanban y guía de la demostración	12	100 %
Fernanda	Database links y cuadre, inventario, perfilado de calidad, requisitos y objetivos, documento APA 7	8	100 %
Joseph	Informes 5 a 7, Tablero, hoja de KPI, diagramas, relaciones de la fuente y conclusiones	10	100 %
Fabio	Vistas para Excel, conexión Excel-Oracle, informes 1 a 4, prueba de recuperación y guía de Excel	6	100 %